

Prevendo a Qualidade de Vinhos com Machine Learning

Da análise química ao vinho premium: o que os dados revelam

O problema: avaliar qualidade é caro, lento e subjetivo

Hoje, a qualidade do vinho é definida por painéis de especialistas.

Um processo que depende de experiência, tempo e disponibilidade de avaliadores.

Mas cada lote já passa por análises químicas de rotina no laboratório: acidez, álcool, densidade, sulfitos...

A pergunta que respondemos:

esses dados químicos conseguem prever, sozinhos, se um vinho será classificado como de alta qualidade?

A regra do jogo

Alta qualidade



nota dos especialistas ≥ 7

Baixa/Média qualidade

nota dos especialistas < 7

1.599 amostras de vinho tinto · 11 características químicas por amostra

Vinho excelente é raro — e isso muda tudo




13,6%

dos vinhos analisados são
de alta qualidade (217 de 1.599)

Por que isso importa: com classes tão desiguais, um modelo que sempre respondesse “vinho comum” acertaria 86% das vezes, sem valor algum para o negócio. Por isso, medimos o sucesso pela capacidade real de encontrar os vinhos premium, não pela taxa bruta de acerto.

O que separa um grande vinho de um vinho comum?

Variáveis mais correlacionadas vs. classe de qualidade



Álcool ↑

Uvas mais maduras produzem vinhos mais encorpados e bem avaliados.


Acidez volátil ↓

É o “toque de vinagre”: o defeito químico que mais derruba a nota.

Sulfatos ↑

Conservantes que protegem o aroma e o frescor do vinho.

As variáveis químicas contam uma história coerente



O mapa de relações confirma a química do vinho:

- Álcool é o fator mais ligado à qualidade (+0,48)
- Acidez volátil é o principal vilão (-0,39)
- Mais ácido $\Rightarrow$ pH menor (-0,68): os dados respeitam a física e a química — sinal de base confiável
- Nenhuma variável sozinha resolve o problema — por isso usamos modelos que combinam todas elas

Como construímos a solução

1

Preparação

Verificamos a base (sem dados faltantes), padronizamos as medidas e criamos indicadores combinados, como álcool × sulfatos.

2

Dois modelos concorrentes

Um modelo simples e transparente (Regressão Logística) contra um modelo mais sofisticado (Random Forest).


3

Teste justo

25% dos vinhos ficaram “escondidos” dos modelos e só foram usados na prova final, com validação cruzada no restante.

Sem termos técnicos no dia a dia: o modelo recebe a análise de laboratório e responde “este lote tem perfil de vinho premium?”

Resultado: 93% de acerto e um vencedor claro



Random Forest


93% de acerto geral

8 em 10 vinhos apontados como premium realmente são

2 em 3 vinhos premium são encontrados automaticamente

O modelo simples encontrava mais vinhos premium, mas errava demais (só 37% dos alertas eram verdadeiros). O Random Forest entrega o melhor equilíbrio entre encontrar e não dar alarme falso.

O que faz um vinho premium, segundo o modelo



Três alavancas para a produção:

- Colher no ponto certo — a maturação da uva (teor alcoólico) é o fator nº 1 de qualidade
- Fermentação sob controle — conter a acidez volátil evita o principal defeito que desclassifica lotes
- Conservação adequada — a dose certa de sulfitos protege aroma e frescor

O modelo confirma o conhecimento dos enólogos — e o transforma em triagem automática e objetiva.

Conclusão: a química prevê a qualidade

Triagem automática

O modelo usa análises que o laboratório já faz — a previsão de qualidade sai praticamente de graça, lote a lote.

Painel sensorial focado

Especialistas passam a degustar apenas os lotes candidatos a premium, economizando tempo e custo.

Decisão no processo

Maturação, fermentação e conservação viram indicadores monitoráveis de qualidade — antes de engarrafar.

Próximos passos: ampliar a base com mais vinhos premium, calibrar o ponto de corte ao custo do negócio e testar modelos de boosting.